

# SISTEMAS INTELIGENTES ARTIFICIALES

---

Prof.: Esp. Ing. Agustín Fernandez

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal**: método causal en el que una variable conocida como variable dependiente está relacionada con una o más variables independientes por medio de una ecuación lineal.
- **Variable dependiente** => es la variable que se desea pronosticar (su comportamiento depende de las variables independientes)
- **Variable independiente** => es la variable que influye en la variable dependiente y por ende son la causa de los resultados obtenidos en el pasado.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Nomenclatura:
- $n$  – escalar o vector.
- $N$  – matriz o tensor.
- $N_{axb}$  – matriz de  $a$  filas y  $b$  columnas.
- $I_n$  – matriz identidad con  $n$  filas y  $n$  columnas.
- $I$  – matriz identidad con dimensiones dadas por el contexto.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Nomenclatura:

$$v = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}_{5 \times 1} \rightarrow v^T = [1 \ 2 \ 3 \ 4 \ 5]_{1 \times 5}$$

$$M = \begin{bmatrix} 11 & 12 & 13 & 14 \\ 21 & 22 & 23 & 24 \\ 31 & 32 & 33 & 34 \end{bmatrix}_{3 \times 4} \rightarrow M^T = \begin{bmatrix} 11 & 21 & 31 \\ 12 & 22 & 32 \\ 13 & 23 & 33 \\ 14 & 24 & 34 \end{bmatrix}_{4 \times 3}$$

$$I_{2 \times 2} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad I_{4 \times 4} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Nomenclatura:
- $n_i$  – elemento i del vector.
- $N_{i,j}$  – elemento de la fila i y columna j.
- $N_{i,*}$  – fila i de la matriz.
- $N_{*,j}$  – columna j de la matriz.
- $N^T$  – transpuesta.
- $N^{-1}$  – inversa. (Mejor usar “pseudoinversa Moore-Penrose”)

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Nomenclatura:

$$v = \begin{bmatrix} 1.45 \\ 4.56 \\ 0.82 \\ 0.44 \\ 1.29 \end{bmatrix} \quad v_1 = 1.45 \quad v_2 = 4.56 \quad v_5 = 1.29$$

$$b = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad c = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix} \quad d = \begin{bmatrix} 7 \\ 8 \\ 9 \end{bmatrix}$$

$$A = \begin{bmatrix} b^T \\ c^T \\ d^T \end{bmatrix} = \begin{bmatrix} \dots b \dots \\ \dots c \dots \\ \dots d \dots \end{bmatrix} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

$$M = \begin{bmatrix} 11 & 12 & 13 & 14 \\ 21 & 22 & 23 & 24 \\ 31 & 32 & 33 & 34 \end{bmatrix}_{3 \times 4} \quad M_{2,*} = [21 \ 22 \ 23 \ 24]$$

$$M_{1,4} = 14 \quad M_{2,3} = 23 \quad M_{*,3} = \begin{bmatrix} 13 \\ 23 \\ 33 \end{bmatrix}$$

$$c = \begin{bmatrix} 4 \\ 8 \\ 1 \\ 6 \end{bmatrix} \rightarrow \text{diag}(c)_{4 \times 4} = \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 8 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 6 \end{bmatrix}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Nomenclatura:**
- m – nro ejemplos de entrenamiento.
- n – nro atributos de cada ejemplo.
- x – variables de entrada.
- y – variables de salida.
- $x_j$  – atributo j de la entrada.
- $(x,y)$  – ejemplo de entrenamiento.
- $(x^{(i)},y^{(i)})$  – el i-ésimo ejemplo.
- $x_j^{(i)}$  – atributo j del ejemplo i.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Nomenclatura: Ejemplo


#	$x_1$ :altura	$x_2$ :anchura	$x_3$ :peso	y:precio
1	1.45	3.61	7.29	154.32
2	0.98	2.55	4.72	109.43
3	2.12	0.89	3.85	133.75
4	1.77	1.76	2.89	102.59
5	1.88	1.81	5.38	176.82

- $m = 5$  ;  $n = 3$  ;  $x_2 = (3.61, 2.55, 0.89, 1.76, 1.81)$
- $(x^{(3)}, y^{(3)}) = (2.12, 0.89, 3.85, 133.75)$
- $x_1^{(4)} = 1.77$  ;  $x_3^{(2)} = 4.72$  ;  $x_3^{(5)} = 5.38$
- $y^{(4)} = 102.59$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:

$$\hat{y} = ax + b$$




La curva o recta de regresión pasa por siempre por el centro de la nube de dispersión.

En mucha bibliografía encontraremos la ecuación escrita así:

$$h_{\theta}(x) = \theta_1 x + \theta_0$$


# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal = salida continua



# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal = salida continua



# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:

$$MSE = J(\theta) = \frac{1}{2n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2$$

El algoritmo de regresión lineal se basa en minimizar el Error Cuadrático Medio (MSE) siguiendo el principio del algoritmo de descenso por el gradiente el cual busca minimizar la función coste llamada


Es decir:

$$\min_{\theta} J(\theta) = \min_{\theta} \left[ \frac{1}{2n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2 \right]$$

$$\min_{\theta} J(\theta) = \min_{\theta} \left[ \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x)^{(i)} - y^{(i)})^2 \right]$$


# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:
- Debemos buscar valores de  $\theta_i$  para los que  $h_{\theta}(x)$  se acerque lo máximo posible a los "y" de los ejemplos de entrenamiento.




# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:
- Como ya dijimos debemos minimizar la función coste  $J(\theta)$  y gráficamente puede verse como:




# APRENDIZAJE AUTOMATICO PUESTO EN PRACTICA

- Regresión lineal:




# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:



# APRENDIZAJE AUTOMATICO PUESTO EN PRACTICA


- Regresión lineal:
- Repetir hasta converger:  $\theta_j \leftarrow \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$



- Mínimo local alcanzado si:  $\frac{\partial}{\partial \theta_j} J(\theta) = 0$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:
- $\alpha$  pequeña: desciende lento, tarda más pero es preciso.
- $\alpha$  grande: desciende rápido, tarda poco pero se podría pasar incluso divergir.



# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal:** derivadas parciales

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n [h_\theta(x^{(i)}) - y^{(i)}]^2$$

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{\partial}{\partial \theta_j} \frac{1}{2n} \sum_{i=1}^n [\theta_1 x^{(i)} + \theta_0 - y^{(i)}]^2$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal:** derivadas parciales

$$\text{Para } j=0 \rightarrow \frac{\partial}{\partial \theta_0} J(\theta) = \frac{\partial}{\partial \theta_0} \frac{1}{2n} [\theta_1 x^{(i)} + \theta_0 - y^{(i)}]^2$$

$$\text{Si: } z = \theta_1 x^{(i)} + \theta_0 - y^{(i)}$$

$$\frac{\partial}{\partial \theta_0} J(\theta) = \frac{1}{2n} \frac{\partial}{\partial \theta_0} [z]^2 = \frac{1}{2n} 2z \frac{\partial}{\partial \theta} z$$

Hacemos la derivada parcial respectode  $\theta_0$ :  $\frac{\partial}{\partial \theta_0} [\theta_1 x^{(i)} + \theta_0 - y^{(i)}] = 1$

Remplazamos en la formula anterior:  $\frac{\partial}{\partial \theta_0} J(\theta) = \frac{1}{n} \sum_{i=1}^n [h_\theta(x^{(i)}) - y^{(i)}]$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal:** derivadas parciales

$$\text{Para } j=1 \rightarrow \frac{\partial}{\partial \theta_1} J(\theta) = \frac{\partial}{\partial \theta_1} \frac{1}{2n} [\theta_1 x^{(i)} + \theta_0 - y^{(i)}]^2$$

$$\text{Si: } z = \theta_1 x^{(i)} + \theta_0 - y^{(i)}$$

$$\frac{\partial}{\partial \theta_1} J(\theta) = \frac{1}{2n} \frac{\partial}{\partial \theta_1} [z]^2 = \frac{1}{2n} 2z \frac{\partial}{\partial \theta_1} z$$

$$\text{Hacemos la derivada parcial respecto de } \theta_1: \frac{\partial}{\partial \theta_1} [\theta_1 x^{(i)} + \theta_0 - y^{(i)}] = x^{(i)}$$

$$\text{Remplazamos en la formula anterior: } \frac{\partial}{\partial \theta_1} J(\theta) = \frac{1}{n} \sum_{i=1}^n [h_\theta(x^{(i)}) - y^{(i)}] \cdot x^{(i)}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal:** Algoritmo
- Mientras los  $\theta$  sigan cambiando {

$$j=0 \rightarrow \frac{\partial}{\partial \theta_0} J(\theta) = \frac{1}{n} \sum_{i=1}^n [h_\theta(x^{(i)}) - y^{(i)}]$$

$$j=1 \rightarrow \frac{\partial}{\partial \theta_1} J(\theta) = \frac{1}{n} \sum_{i=1}^n [h_\theta(x^{(i)}) - y^{(i)}] \cdot x^{(i)}$$

$$\theta_0 \leftarrow \theta_0 - \alpha \cdot \frac{\partial}{\partial \theta_0} J(\theta)$$

$$\theta_1 \leftarrow \theta_1 - \alpha \cdot \frac{\partial}{\partial \theta_1} J(\theta)$$

}

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal**: Algoritmo vectorizado (para múltiples variables)
  - Repetir hasta que se cumpla condición de parada:
  - Salida:  $H = X^T \Theta$
  - Error:  $D = H - Y$
  - Coste:  $j = \frac{1}{2n} D^T D$
  - Actualización:  $\Theta = \Theta - \alpha \cdot \frac{1}{n} X D$
  - Condición de parada (variantes):  $j_t - j_{t-1} < \varepsilon$  ó  $\Theta_t - \Theta_{t-1} < \varepsilon$
- $X$  = Matriz fila, en donde cada ejemplo es una fila y cada columna un atributo (no olvidar fila para BIAS)

$=$  Vector columna (cada fila es el parámetro correspondiente a cada atributo)

$=$  Vector columna (cada fila es el valor correspondiente a cada una de las estimaciones realizadas)

$=$  Vector columna (cada fila es el valor correspondiente a cada una de las salidas conocidas)

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal**: Algoritmo vectorizado (para múltiples variables)

$$h_{\theta}(x^{(i)}) = \sum_{j=1}^n x_j^{(i)} \cdot \theta_j : x_0^{(i)} = 1$$

$$\begin{array}{c}
 \begin{array}{c}
 \left[ \begin{array}{ccc} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} \\ x_1^{(2)} & x_2^{(2)} & x_3^{(2)} \\ x_1^{(3)} & x_2^{(3)} & x_3^{(3)} \\ x_1^{(4)} & x_2^{(4)} & x_3^{(4)} \\ x_1^{(5)} & x_2^{(5)} & x_3^{(5)} \end{array} \right] \rightarrow \left[ \begin{array}{cccc} 1 & x_1^{(1)} & x_2^{(1)} & x_3^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & x_3^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & x_3^{(3)} \\ 1 & x_1^{(4)} & x_2^{(4)} & x_3^{(4)} \\ 1 & x_1^{(5)} & x_2^{(5)} & x_3^{(5)} \end{array} \right] \cdot \left[ \begin{array}{c} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{array} \right] = \left[ \begin{array}{c} h_{\theta}(x^{(1)}) \\ h_{\theta}(x^{(2)}) \\ h_{\theta}(x^{(3)}) \\ h_{\theta}(x^{(4)}) \\ h_{\theta}(x^{(5)}) \end{array} \right]
 \end{array} \\
 \begin{array}{ccccc}
 5 \times 3 & & 5 \times 4 & & 4 \times 1 \\
 m \times n & \rightarrow & m \times (n+1) & \cdot & (n+1) \times 1 \\
 X^T & & [1 \ X^T] & & \Theta
 \end{array} \\
 H = X^T \Theta
 \end{array}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal**: Algoritmo vectorizado (para múltiples variables)

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m [h_\theta(x^{(i)}) - y^{(i)}]^2$$

$$\begin{matrix} \begin{bmatrix} h_\theta(x^{(1)}) \\ h_\theta(x^{(2)}) \\ h_\theta(x^{(3)}) \\ h_\theta(x^{(4)}) \\ h_\theta(x^{(5)}) \end{bmatrix} & - & \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ y^{(4)} \\ y^{(5)} \end{bmatrix} & = & \begin{bmatrix} h_\theta(x^{(1)}) - y^{(1)} \\ h_\theta(x^{(2)}) - y^{(2)} \\ h_\theta(x^{(3)}) - y^{(3)} \\ h_\theta(x^{(4)}) - y^{(4)} \\ h_\theta(x^{(5)}) - y^{(5)} \end{bmatrix} \\ 5 \times 1 & & 5 \times 1 & & 5 \times 1 \\ m \times 1 & & m \times 1 & & m \times 1 \\ H & - & Y & = & D \end{matrix}$$

$$J(\theta) = j = \frac{1}{2m} D^T D$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Regresión lineal**: Algoritmo vectorizado (para múltiples variables)

$$\theta_j \Leftarrow \theta_j - \alpha \cdot \frac{\partial}{\partial \theta_j} J(\theta) \quad : \quad \frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m [h_\theta(x^{(i)}) - y^{(i)}] \cdot x_j^{(i)}$$

$$X = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(m)} \\ x_2^{(1)} & x_2^{(2)} & \dots & x_2^{(m)} \\ \dots & \dots & \dots & \dots \\ x_n^{(1)} & x_n^{(2)} & \dots & x_n^{(m)} \end{bmatrix}_{(n+1) \times m}$$

$$D = \begin{bmatrix} h_\theta(x^{(1)}) - y^{(1)} \\ h_\theta(x^{(2)}) - y^{(2)} \\ \dots \\ h_\theta(x^{(m)}) - y^{(m)} \end{bmatrix}_{m \times 1}$$

$$\Theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}_{(n+1) \times 1}$$

$$\Theta = \Theta - \alpha \cdot \frac{1}{m} X D$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal:

$$b = \bar{y} - a\bar{x}$$

Coeficiente de regresión o

$$a = \frac{n \sum x^{(i)}y^{(i)} - \sum x^{(i)} \sum y^{(i)}}{n \sum (x^{(i)})^2 - (\sum x^{(i)})^2}$$

Pendiente o

Esto es para calcular (estadísticamente) los valores para la pendiente y la ordenada al origen.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: medidas a tener en cuenta
- Coeficiente de correlación (R): es la medida que indica el nivel de asociación entre las variables dependiente e independiente.

- Es adimensional:
  - Si  $R = 0$  son variables independientes.
  - Si  $R = 1$  relación lineal exacta.
  - Si  $R > 0$  relación directa. Al aumentar x también aumenta y
  - Si  $R < 0$  la relación inversa. Si una variable aumenta la otra disminuye

$$R = \frac{\sum \hat{y}^{(i)} - \bar{y}}{\sum y^{(i)} - \bar{y}}$$

- Coeficiente de determinación (): es una medida que indica porcentualmente el cambio de la variable dependiente respecto a la independiente. Da valores entre 0 y 1. Mientras mas cerca de 1 mejor.

$$R^2 = \frac{\sum (\hat{y}^{(i)} - \bar{y})^2}{\sum (y^{(i)} - \bar{y})^2} \times 100$$

Es la estimación de «y» según el modelo encontrado

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: medidas a tener en cuenta
  - Error absoluto medio (EAM): (Mean absolute error) es un promedio de la suma de los errores de los valores predichos ante los valores realmente observados
- $$EAM = \frac{\sum |\hat{y}^{(i)} - y^{(i)}|}{n}$$
- Raíz del error cuadrático medio (RECM): (Root mean squared error) es la raíz cuadrada del promedio de la suma de los errores de los valores predichos ante los valores realmente observados elevados al cuadrado. Un valor igual a cero significa ajuste perfecto.

$$RECM = \sqrt{\frac{\sum (\hat{y}^{(i)} - y^{(i)})^2}{n}}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: medidas a tener en cuenta
- Error relativo absoluto (ERA): (Relative absolute error) es un porcentaje que relaciona las diferencias de la sumatoria de los errores predichos y los valores reales con respecto a la sumatoria de la diferencia entre la media y los valores realmente observados.

$$E R A = \frac{\sum |\hat{y}^{(i)} - y^{(i)}|}{\sum |\bar{y} - y^{(i)}|} \times 100$$

La diferencia entre relativo y absoluto es que el error absoluto es cuánto se desvía el resultado de el valor real. Y el error relativo es una medida en porcentaje en comparación con el valor real.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: medidas a tener en cuenta
- Raíz del error cuadrático relativo(RECR): (Root relative squared error) es un porcentaje que se calcula tomando la raíz cuadrada que relaciona las diferencias de la sumatoria de los errores predichos y los valores reales con respecto a la sumatoria de la diferencia entre la media y los valores realmente observados.

$$R E C R = \sqrt{\frac{\sum(\hat{y}^{(i)} - y^{(i)})^2}{\sum(\bar{y} - y^{(i)})^2}} \times 100$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: medidas a tener en cuenta
- Suma de cuadrados de error (): es la parte de la variabilidad de la variable dependiente que no conseguimos explicar con el modelo.

$$S_r = \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2$$

- Error estándar(): es el valor que cuantifica cuanto se apartan los valores de la media de la población.

$$\hat{\sigma} = \sqrt{S_r \cdot \frac{1}{n - 1}}$$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: Ejemplo de calculo estadístico

Inversión (millones) x	Ventas (millones) y	$x \cdot y$	$x^2$	$\hat{y} = ax + b$	$y - \hat{y}$
1	2	2	1	2,539	-0,539
2	3	6	4	3,208	-0,208
2	4	8	4	3,208	0,792
3	4	12	9	4,057	-0,057
4	4	16	16	4,906	-0,906
4	6	24	16	4,906	1,094
5	5	25	25	5,755	-0,755
6	7	42	36	6,604	0,396
$\sum x_i = 27$	$\sum y_i = 35$	$\sum xy = 135$	$\sum x^2 = 111$		

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Regresión lineal: Ejemplo

$$a = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} = \frac{8 \cdot 135 - 27 \cdot 35}{8 \cdot 111 - 27^2} = \frac{45}{53} = 0,849$$

$$b = \bar{y} - a\bar{x} = \frac{35}{8} - \frac{45}{53} \cdot \frac{27}{8} = \frac{80}{53} = 1,509$$

**Modelo:**  $y = 0,849x + 1,509$

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Utilizaremos WEKA para realizar las practicas de regresión lineal y arboles de regresión:
  - **Regresión lineal:** Abra Weka e ingrese al explorer, una vez allí abra el archivo Behavior\_of\_the\_urban\_traffic.arff el cual contiene los datos del comportamiento del trafico de las calles de Sao Paulo (Brasil). Dicho set de datos tiene un conjunto de varios atributos y observe que el atributo «Slowness\_in\_traffic\_percent» es de tipo real y representa el porcentaje de **ralentización** que se produce en el trafico en base al resto de los atributos como son: colectivos detenidos, semáforos apagados, semáforos intermitentes, etc.
    - Seleccione los atributos:
      - Fire\_vehicles, Lack\_of\_electricity, Point\_of\_flooding, Defect\_in\_the\_network\_of\_trolleybuses, Semaphore\_off, Intermittent\_Semaphore y Slowness\_in\_traffic\_percent
    - Invierta la selección y remueva los atributos que quedaron seleccionados.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Luego vaya a la pestaña Classify y dentro de functions elija LinearRegresion.
- Luego seleccione «start»
- Observe la salida de Weka y pegue la función de predicción obtenida en un archivo excel e intente predecir cual será el porcentaje de ralentización del trafico si ocurre la siguiente situación:

Fire_vehicles	Lack_of_electricity	Point_of_flooding	Defect_in_the_network_of_trolleybuses	Semaphore_off	Intermittent_Semaphore
10	5	6	1	10	6

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- **Salida de Weka:**

```
==> Classifier model (full training set) ==>

Linear Regression Model

Slowness_in_traffic_percent =
    7.1437 * Fire_vehicles +
    2.0019 * Lack_of_electricity +
    2.0194 * Point_of_flooding +
    -1.088 * Defect_in_the_network_of_trolleybuses +
    1.3742 * Semaphore_off +
    -3.8563 * Intermittent_Semaphore +
    9.6563

Time taken to build model: 0 seconds

==> Evaluation on training set ==>

Time taken to test model on training data: 0.01 seconds

==> Summary ==>

Correlation coefficient          0.5934
Mean absolute error              2.6682
Root mean squared error          3.4989
Relative absolute error          80.0819 %
Root relative squared error     80.4882 %
Total Number of Instances        135
```

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

- Ejercicio sobre regresión lineal y arboles de regresión:
  - **Ejercicio de Regresión lineal:** Abra Weka e ingrese al explorer, una vez allí abra el archivo housing.arff el cual contiene los datos de vivienda de Boston teniendo en cuenta ciertos parámetros.
  - Construya el modelo de regresión lineal y observe el coeficiente de correlación y los errores obtenidos.
  - **Ejercicio de Árbol de Regresión:** utilice el mismo archivo housing.arff y construya el clasificador utilizando el algoritmo M5P (dentro de «trees»).
  - Compare con el modelo anterior el coeficiente de correlación y los errores obtenidos.

# APRENDIZAJE AUTOMÁTICO PUESTO EN PRACTICA

Ejemplo con código

# APRENDIZAJE AUTOMÁTICO: Utilidades

- Links útiles:

- <https://mvnrepository.com/artifact/nz.ac.waikato.cms.weka/weka-stable>
- <https://archive.ics.uci.edu/ml/datasets.php>
- <https://datahub.io/sports-data/spanish-la-liga#resource-season-1819>
- <https://sourceforge.net/projects/meka/files/Datasets/>
- <https://www.cs.waikato.ac.nz/~ml/weka/downloading.html>